

SigLA 周进展汇报

一句话结论

本周完成方法转向与四段实证闭环:从「前期校准决策 / 抗漂移」路线收尾,转入主线「LLM 自举的开放词表持续学习」,并干净地把它落到论文要回答的真实问题——对从未见过的异常类型做检测与前兆早预警。

本周主线进展

1. 前期路线收尾

- decider 决策器价值经实验确认:真实但幅度有限。
- 在线抗漂移自适应单独不足以解决问题。
- 据此决定转向开放词表持续学习作为主贡献。

2. Task A — 单新类开放词表分类闭环

闭环成立:证据门控发现新类 → LLM 命名 → 扩词表(grow head)→ 类平衡在线重训,全程无人工标注。

5 seed + 双对照臂(后段=新类涌现后):

臂	整体准确率	新类 correlation_break	标注成本
frozen(闭集下界)	48.9% ± 2.4%	0.0%	0
bootstrap(本方法)	74.7% ± 7.7%	57.2% ± 16.8%	LLM 31.4%(43%→17% 衰减)
oracle(人工上界)	97.0% ± 1.7%	95.3% ± 3.7%	人工 24.5%
llm_only(逐窗分类)	21.2% ± 2.5%	—	100%

- 与上界差距(~22pt)纯来自 LLM 标注噪声,方法天花板高。
- 逐窗 LLM 直接分类仅 21% — 不是好分类器。
- 关键发现:"列举全部取非已知"命名优于 top-1 prompt(57% vs 29%)。

3. Task B — 多新类涌现(06-17)

- 打破 multi-type blocker:根因是证据不正交(trend↔level_shift、variance_burst↔spike/oscillation 纠缠误触已知签名)。
- 新建正交基准 sigla_exp/ovbench.py ,使每概念恰好且仅触发自己的签名;命名喂 z-score 而非原始值。

3 新类错峰涌现,5 seed:

	frozen	bootstrap
全段(3 新类活跃)	50.6% $\pm$ 4.8%	88.1% $\pm$ 2.9%
variance_burst	0%	67% $\pm$ 2%
trend	0%	100% $\pm$ 0%
correlation_break	0%	56% $\pm$ 11%

词表 100% 长全(3→6),warm-up 期无提前建类。

4. 检测桥(route B bridge,06-17d)

回答审稿人核心问题:开放词表对检测(而非仅分类)有用吗?

指标(涌现后,5 seed)	frozen	bootstrap
新类检测召回(argmax≠normal)	15% $\pm$ 30%(4/5 seed=0%)	88% $\pm$ 6%
整体检测 F1	0.82 $\pm$ 0.06	0.87 $\pm$ 0.03
整体检测召回	0.78 $\pm$ 0.08	0.97 $\pm$ 0.02

- 闭集检测器把新类 correlation_break 自信判成 normal → 完全漏检。
- 本方法把新类检测召回从 ~0% 救回 88%,整体召回 0.78→0.97。

5. 类型化前兆早预警(D,06-18)

把闭环接到论文真正的「问题」:前兆窗内报出正确的新异常类型。

	frozen	bootstrap
类型化早预警 recall	0% $\pm$ 0%	100% $\pm$ 0%
lead-time(窗)	—	8.0(满前兆窗宽)
类型 FAR(正常被判 T)	0.0%	4.8%(受控)

- frozen 永远命名不出新类型;bootstrap 提前 8 窗报出正确新类型,全程无标注。

诚实 caveat(已记录,非阻塞)

- correlation_break 最弱最抖(56% $\pm$ 11%);variance_burst 命名 64%。
- 在线重训侵蚀二分类 score 校准(boot 二分类 FAR 38%);类型化口径不受影响。
- "frozen 类型化 EW=0" 部分 by construction,价值在于 lead-time + 无标注自举 + 低 type-FAR 的端到端演示。

下一步

- 文献定位:与 LLM-as-labeler / novel-class-detection / open-vocab AD 的差异点。

- 多 novel × 多 seed 扩展;加强 correlation_break / variance_burst 签名判别度与注入强度。
- 把类型化早预警接到二分类检测端到端。

图表

由 `scripts/make_weekly_figs.py` 生成;合并版 PDF:[weekly_report_figs.pdf](#)

图1 Task A 四个对照臂(下界→本方法→上界,成本对照)




图2 新类召回:闭集真的是 0%




图3 主线四段:闭集做不到 → 本方法救回

图3 主线四段:闭集做不到 → 本方法救回(越右越接近论文问题)




图4 检测桥:整体召回 0.78→0.97 几乎全来自救回漏检新类

图4 检测桥:召回 0.78→0.97 的提升几乎全来自救回漏检新类




图5 类型化早预警:bootstrap 提前 8 窗报对类型,frozen 全程为 0

图5 类型化早预警:bootstrap 提前 8 窗报对类型,frozen 全程为 0




图6 越学越准、越来越不靠 LLM

图6 Task A:越学越准(↑),越来越不靠 LLM(↓)

