

异常画像刻画问题

将时间序列划分为窗口 W_j ，并通过 Concept Profile Extractor 提取 spike、level、season、context、corr 等异常概念强度，得到 concept profile。——【Concept Profile构造-五种mask版本.pdf】

挑战：构造 concept profile 的难点在于，时间序列本身就存在自然波动。如果我们使用统计方法去检测 spike、seasonal anomaly 或 level shift 这类概念，那么这些 concept score 可能也会在正常波动处升高。因此，方法可能会把正常变化错误地标记为与异常相关的概念，从而造成错误的 concept 激活。

另一个问题是，当真实异常发生时，多个 concept score 可能会同时对同一个异常事件产生响应。因为很多 concept score 不是“真正机制”的分数，而是“某种统计现象”的分数。例如，如果真实异常是一个 spike，那么 spike score 会升高，但 seasonal anomaly score 和 level-shift score 也可能在同一个时间点附近升高。换句话说，一个单一异常可能会让多个 concept score 同时升高，但这并不意味着系统中同时发生了多种异常机制。

因此 concept profile 构造的挑战在于：它可能同时受到两类问题影响。第一，正常波动可能导致错误激活；第二，一个真实异常可能触发多个统计分数，导致不同 concept 之间出现重叠激活。

我个人解决思路是：采用 **Synthetic-supervised Calibrated and Disentangled Concept Profiling**（合成监督的校准去纠缠异常概念画像构造方法）。即：先用人为设计的信号证据描述窗口，再用 **TimeRCD 合成数据**里的异常开关作为监督，训练一个轻量 concept extractor 学会把这些证据组合成 concept profile；最后用真实数据校准正常波动，并用去污染机制区分主导 concept 和伴随 concept。

这不是完全替代原统计 mask，而是把原统计 mask 从最终 concept profile 降级为 evidence features，再结合傅里叶、小波、真实校准和去纠缠生成最终 concept profile。

PS: TimeRCD是什么——这篇论文中含有合成数据构造机制。

TimeRCD 论文里的合成数据生成机制比简单的“spike / level shift / seasonal break / contextual deviation / correlation break”更复杂。它大致分四层：

第一层是正常序列生成。每个通道的正常信号由 trend、seasonality 和 noise 组成：

$$x_{base}(t) = T(t) + S(t) + \epsilon(t)$$

其中 trend 可以是确定性或随机趋势，seasonality 可以由 sinusoid、square、triangle、wavelet atoms 等周期原子组成，noise 还可以有 piecewise volatility。

第二层是多变量因果结构。TimeRCD 会先采样一个 DAG，然后用 ARX 动态生成变量之间的因果依赖和传播关系：

$$z_i[t] = a_i z_i[t-1] + \sum_{j \in P(i)} b_{ij} x_j[t - \ell_{ij}] + c_i$$

这说明它不是只做单变量异常，而是显式模拟了多变量因果依赖和跨变量传播。

第三层是异常注入。它有两类异常注入方式：

1. **Exogenous anomaly**：外部冲击，先生成正常多变量系统，再在某个通道某个窗口上覆盖或叠加异常模板；
2. **Endogenous anomaly**：内部系统故障，先在父节点 baseline 上施加异常，然后通过 ARX 动态自然传播到下游变量。

第四层是具体异常类型。论文附录 C.4 给了完整 taxonomy，至少包括：

- upward spike / downward spike；
- continuous spikes；
- wide spike；

- outlier;
- sudden increase / sudden decrease, 也就是 level shift;
- convex / concave plateau;
- rapid rise followed by slow decline;
- slow rise followed by rapid decline;
- spike + level interaction;
- shake, 高频振动;
- waveform inversion;
- amplitude scaling;
- frequency change;
- noise injection;
- waveform change;
- phase shift;
- add / remove harmonic;
- pulse shift;
- pulse width modulation;
- wavelet family / scale / shift / amplitude changes 等。

所以对应到你说的几个 concept:

我们说的 concept	TimeRCD 合成机制里有没有对应
spike	有, 而且很多种: upward/downward spike、continuous spike、wide spike、outlier
level shift	有: sudden increase/decrease、plateau、spike + level interaction
seasonal break	有: frequency change、phase shift、harmonic add/remove、waveform change、pulse modulation、wavelet seasonal change
contextual deviation	有, 但不是简单叫这个名字; 它通过“相对于趋势、周期、因果上下文的违背”来构造
correlation break	不一定以这个名字直接注入, 但通过 DAG / ARX causal propagation 和 endogenous anomalies, 会产生跨变量依赖结构变化

所以可以用 TimeRCD 合成数据里的异常开关作为监督, 训练一个轻量 concept extractor。

比如合成数据里我们知道真实开关:

- 打开 spike 开关 → 注入 spike
- 打开 level shift 开关 → 注入 level shift
- 打开 frequency change 开关 → 注入 seasonal / spectral change

那就可以检查 concept profile 是否输出符合预期 (直观举例):

- 注入 spike 后, spike concept 是否最高?
- 注入 level shift 后, level concept 是否最高?
- 注入 frequency change 后, seasonal / spectral concept 是否最高?

下面介绍Synthetic-supervised Calibrated and Disentangled Concept Profiling（合成监督的校准去纠缠异常概念画像构造方法）：

第一步：先提取可解释信号证据

这里仍然需要人为设计一些证据特征。这些特征包括：

A. Spike / burst 相关证据

中文	English	来源	含义和用途
Hampel 幅值异常证据	Hampel amplitude evidence	原文件（Label Generation (Explanation).pdf）已有	判断当前点的幅值是否相对于局部正常范围显著偏离，用于支持 spike。
一阶差分 / 导数异常证据	first-difference / derivative evidence	原文件已有	判断当前点是否存在突然跳变。若相邻时间点差分很大，说明可能存在突发变化。
峰值突出度证据	peak prominence evidence	原文件已有	判断当前点是否形成明显局部峰值，用于增强 spike 证据的可信度。
局部高频能量	localized high-frequency energy	新增小波	判断短时间位置是否出现高频能量集中。高值通常支持 spike / burst。
小波局部性	wavelet locality	新增小波	判断高频能量是否集中在窗口内很短的一段时间。局部性越强，越支持短时 spike / burst。
突发持续时间	burst / transient duration	新增小波	判断突发响应持续多久。持续时间短支持 spike / burst；如果持续时间很长，则不应简单解释为 spike。
短时冲击强度	transient shock intensity / burst strength	新增小波	判断局部冲击强度是否足够强，用于支持 spike / burst。

B. Level shift 相关证据

中文	English	来源	含义和用途
左右窗口稳健中位数差异	two-sided robust median difference	原文件已有	比较变化点前后两个窗口的稳健中位数是否明显不同，用于判断是否存在水平切换。
CUSUM 变化统计量	CUSUM change statistic	原文件已有	检测序列是否从某个时间点开始持续偏离原来的水平，用于支持 level shift。
持续性	persistence	原文件含义中已有	判断水平变化是否持续存在。真正的 level shift 不应只持续一两个点。
长持续时间	long duration	新增约束	判断异常是否在较长时间内维持新水平。长持续时间支持 level shift，短持续时间更像 spike / burst。
变化后稳定性	stability after shift	新增约束	判断变化后是否形成新的稳定水平。如果变化后很快恢复原水平，则不应认为是真正 level shift。

CUSUM 全称是 **Cumulative Sum**，中文可以叫**累积和变化统计量**。它用来检测一个序列是否从某个时间点开始持续偏离原来的水平。

C. Seasonal break 相关证据

中文	English	来源	含义和用途
同周期相位偏离	phase-specific deviation / deviation from seasonal quantiles	原文件已有	判断当前值是否偏离历史同周期相位的正常范围。它本身可支持 contextual deviation，也可作为 seasonal break 的初始证据。
周期能量变化	periodogram energy change	原文件已有	判断正常季节性频率附近的能量是否发生变化，用于支持 seasonal break。
频谱距离	spectral distance	新增傅里叶	比较当前窗口频谱与同上下文正常频谱的整体差异，用于判断周期 / 频谱结构是否真的改变。
主频偏移	dominant frequency shift / peak frequency shift	新增傅里叶	判断主要周期频率是否发生偏移。主频变化更支持 seasonal / spectral break。
周期能量损失	periodic energy loss	新增傅里叶，对 periodogram evidence 的扩展	判断正常周期主频附近的能量是否减弱或消失，用于判断周期结构是否被破坏。
频谱熵	spectral entropy	新增傅里叶	判断频谱能量是否变得分散。频谱熵升高可能说明周期结构变乱。

同周期相位偏离需要特别说明：如果只是某个值偏离历史同相位正常范围，但频谱结构没有变化，更偏向 **contextual deviation**；如果同时伴随频谱距离增大、主频偏移或周期能量损失，则更支持 **seasonal break**。

D. Contextual deviation 相关证据

中文	English	来源	含义和用途
条件范围偏离	conditional range deviation	原文件已有	判断当前值是否超出近期上下文条件下的正常范围。
中位数基线预测误差	median-baseline prediction error	原文件已有	用近期中位数作为简单上下文基线，判断当前值相对该基线是否偏离。
预测误差鲁棒 z-score	robust z-score on prediction errors	原文件已有	判断当前预测误差是否显著大于正常误差波动范围。
同工况正常参考残差	same-regime normal-reference residual / context-conditioned residual	新增真实校准	判断当前值在同工况、同负载、同模式下是否不合理，用于减少正常工况变化造成的误激活。
上下文似然 / 条件合理性	context likelihood / context-conditioned plausibility	可选扩展	如果有条件概率模型，可用来判断当前窗口在给定上下文下是否低概率。没有条件模型时可不加入。

E. Correlation break 相关证据

中文	English	来源	含义和用途
滑动窗口相关矩阵	sliding-window correlation matrix	原文件已有	在局部时间窗口内计算多变量相关矩阵，作为判断变量关系变化的基础。

中文	English	来源	含义和用途
当前相关矩阵与参考相关矩阵距离	window-to-reference correlation distance	原文件已有	比较当前相关矩阵与正常参考相关矩阵的差异，用于判断整体相关结构是否变化。
节点级相关偏移	node-level correlation deviation	原文件已有	定位哪些变量的相关关系变化最明显，用于解释 correlation break 的来源变量。
变量对关系变化	variable-pair relation change	从相关矩阵条目扩展	判断具体哪些变量对之间的关系发生变化，比整体相关矩阵距离更细粒度。

注意：这一步不是最终判断。它只是收集证据。也就是说，这一步得到的不是最终 concept profile，而是后续轻量 concept extractor 的输入证据 $\mathbf{e}_j$ 。

例如，一个窗口可能出现如下证据模式：

Hampe1 幅值异常证据 = 高
一阶差分 / 导数异常证据 = 高
峰值突出度证据 = 高
小波局部性 = 高
突发持续时间 = 短
频谱距离 = 低
主频偏移 = 低
左右窗口稳健中位数差异 = 中等

这些证据说明：窗口中可能存在一个短时局部突发。但它们还不能直接等同于最终判断：

这个窗口一定是 spike

更准确地说，这些证据只是说明：

局部幅值和导数变化很强；
小波显示高频能量集中在短时间位置；
傅里叶显示整体频谱结构没有明显改变；
Level1 相关证据有一定响应，但可能是局部突发造成的副作用。

因此，第一步的作用只是把原始时间序列窗口转化为一组可解释证据特征：

$$\mathbf{e}_j = [e_j^{spike}, e_j^{level}, e_j^{season}, e_j^{context}, e_j^{corr}, e_j^{fourier}, e_j^{wavelet}]$$

后续再由轻量 concept extractor 学习这些证据如何组合成最终的 5 个 concept：

$$\hat{\mathbf{c}}_j = [\hat{c}_j^{spike}, \hat{c}_j^{level}, \hat{c}_j^{season}, \hat{c}_j^{context}, \hat{c}_j^{corr}] = f_{\theta}(\mathbf{e}_j)$$

其中最终 concept 仍然是原来的五类：spike、level shift、seasonal break、contextual deviation、correlation break

新增的傅里叶、小波、持续性、变化后稳定性等内容不是新的 concept，而是帮助判断这五类 concept 是否真实成立的 evidence features。

为什么需要在原有证据之外加入傅里叶：

原文件中 seasonal break 已经包含两类证据：第一，当前值是否偏离历史同周期相位的正常分位数；第二，局部 periodogram energy 是否在季节频率附近发生变化。这已经是一个合理的初始设计，但它仍然可能遇到一个问题：

一个局部 spike 或 burst 也会造成 seasonal residual 升高。

也就是说，当前点偏离历史同周期相位，并不一定说明周期结构本身坏了。

例如，某个时间点按照历史同周期相位应该接近 10，但当前突然出现 80。此时 seasonal residual 会很高，但真实机制可能只是一个局部 spike，而不是 seasonal break。

所以需要加入傅里叶证据。傅里叶不是为了替代原有 seasonal evidence，而是为了进一步验证当前窗口的整体周期 / 频谱结构是否真的发生了变化。

给定窗口：

$$W_j = \{x_j[0], x_j[1], \dots, x_j[L-1]\}$$

对其做离散傅里叶变换：

$$X_j[k] = \sum_{n=0}^{L-1} x_j[n] \exp\left(-i \frac{2\pi kn}{L}\right), \quad k = 0, \dots, L-1$$

频谱能量为：

$$P_j[k] = |X_j[k]|^2$$

为了让不同窗口的频谱可以比较，先做归一化：

$$p_j[k] = \frac{P_j[k]}{\sum_{r=0}^{L-1} P_j[r] + \epsilon}$$

其中 $p_j[k]$ 表示窗口 W_j 在频率 k 上的相对能量。

设 $p_{z_j}^{normal}[k]$ 为真实正常参考窗口中、同上下文 z_j 下的正常频谱。这里的 z_j 可以表示同工况、同负载、同周期相位或同设备状态。然后可以定义以下傅里叶证据。

1. 频谱距离

$$s_j^{spec} = \frac{1}{2} \sum_k |p_j[k] - p_{z_j}^{normal}[k]|$$

它衡量当前窗口整体频谱结构与同上下文正常频谱结构的差异。

如果 s_j^{spec} 低，说明当前窗口虽然可能有局部偏离，但整体频谱结构仍接近正常参考。

如果 s_j^{spec} 高，说明当前窗口的频率结构发生了明显变化，更支持 seasonal / spectral break。

2. 主频偏移

当前窗口主频定义为：

$$k_j^{peak} = \arg \max_k p_j[k]$$

正常参考主频为：

$$k_{normal, z_j}^{peak} = \arg \max_k p_{z_j}^{normal}[k]$$

主频偏移为：

$$s_j^{peakshift} = |k_j^{peak} - k_{normal, z_j}^{peak}|$$

它衡量当前窗口的主要周期频率是否偏离正常周期频率。

如果主频没有明显变化，即使 seasonal residual 升高，也不应轻易认为发生了 seasonal break。

3. 周期能量损失

设 B_0 表示正常周期主频附近的频率带，则当前周期能量为：

$$E_j(B_0) = \sum_{k \in B_0} p_j[k]$$

正常周期能量为：

$$E_{z_j}^{normal}(B_0) = \sum_{k \in B_0} p_{z_j}^{normal}[k]$$

周期能量损失定义为：

$$s_j^{periodloss} = \max \left(0, \frac{E_{z_j}^{normal}(B_0) - E_j(B_0)}{E_{z_j}^{normal}(B_0) + \epsilon} \right)$$

它衡量原本稳定存在的周期成分是否减弱或消失。

如果正常周期频带的能量明显下降，说明周期结构可能被破坏，更支持 seasonal break。

4. 频谱熵

$$s_j^{entropy} = - \sum_k p_j[k] \log(p_j[k] + \epsilon)$$

频谱熵衡量频谱能量是否变得分散。正常周期信号的频谱能量通常集中在少数频率上；如果频谱熵升高，说明频率结构可能变得混乱。

因此，傅里叶证据可以作为 seasonal break 的验证门控：

$$c_j^{season,valid} = c_j^{season,raw} \cdot g(s_j^{spec}, s_j^{peakshift}, s_j^{periodloss}, s_j^{entropy})$$

其中，

$$g(\cdot) = \sigma \left(\alpha_1 s_j^{spec} + \alpha_2 s_j^{peakshift} + \alpha_3 s_j^{periodloss} + \alpha_4 s_j^{entropy} \right)$$

如果 $c_j^{season,raw}$ 高，但 s_j^{spec} 、 $s_j^{peakshift}$ 、 $s_j^{periodloss}$ 、 $s_j^{entropy}$ 都低，说明 seasonal raw score 的升高可能只是局部 spike / burst 或上下文残差造成的，不支持真实 seasonal break。

如果 $c_j^{season,raw}$ 高，并且傅里叶证据也高，则说明当前窗口不仅偏离了历史同周期相位，而且整体频谱结构也发生变化，更支持 seasonal break。

所以傅里叶主要解决的问题是：区分“局部偏离周期预测”与“真正周期 / 频谱结构异常”。

傅里叶的局限：

普通傅里叶把整个窗口作为一个整体来分析，输出的是窗口级频谱。它能告诉我们：

这个窗口的频谱结构是否变化；
主频是否偏移；
周期能量是否下降；
频谱是否变乱。

但它不擅长告诉我们：

异常发生在窗口的哪个时间位置；
高频能量是短时集中出现，还是整个窗口持续存在；
当前异常是局部 **spike / burst**，还是持续震荡或 **level shift**。

例如：

序列 A: 10, 10, 10, 80, 10, 10
序列 B: 10, 80, 10, 80, 10, 80

两者都可能包含高频成分，但 A 是局部 spike，B 更像持续震荡。普通傅里叶主要看到的是频率成分，不擅长定位高频能量出现的时间位置。

因此，傅里叶适合验证 seasonal / spectral break，但不足以解决 spike / burst 与 level shift、seasonal break 之间的去纠缠问题。

这就是为什么我又引入小波变换。

小波变换的作用是提供时间-频率局部化证据。它不仅看有没有高频能量，还看高频能量出现在窗口的哪个时间位置、持续多久。

给定窗口信号 $x_j(t)$ ，连续小波变换可以写为：

$$W_j(a, b) = \int x_j(t) \psi_{a,b}(t) dt$$

其中：

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right)$$

这里：

- a 是尺度，近似对应频率。小尺度通常对应高频，大尺度对应低频；
- b 是时间位置；
- $W_j(a, b)$ 表示窗口在时间位置 b 、尺度 a 上的局部时频响应。

小波能量为：

$$E_j(a, b) = |W_j(a, b)|^2$$

设 A_{high} 表示高频尺度集合，则高频局部能量为：

$$E_j^{high}(b) = \sum_{a \in A_{high}} |W_j(a, b)|^2$$

它表示在时间位置 b 附近的高频异常能量强度。

进一步定义小波局部性：

$$Locality_j = \frac{\max_b E_j^{high}(b)}{\sum_b E_j^{high}(b) + \epsilon}$$

如果 $Locality_j$ 高，说明高频能量集中在一个很短的时间位置，更像局部 spike / burst。

如果 $Locality_j$ 低但总高频能量高，说明高频能量分散在整个窗口，更像持续震荡或噪声增强。

还可以定义突发持续时间：

$$Duration_j = \frac{1}{L} \sum_b \mathbb{I}(E_j^{high}(b) > \theta_{high})$$

其中 θ_{high} 是高频能量阈值, $Duration_j$ 表示高频能量显著升高的时间比例。

短持续性可以写成:

$$ShortDuration_j = 1 - Duration_j$$

最终可以构造 spike / burst 证据:

$$c_j^{spike,evi} = \tilde{e}_{spike,1}(j) \cdot Locality_j \cdot ShortDuration_j \cdot Recovery_j$$

其中 $\tilde{e}_{spike,1}(j)$ 可以来自原文件中的 Hampel 幅值异常证据或窗口级 spike evidence, $Recovery_j$ 表示异常后是否快速回到正常水平。

小波主要解决的问题是: 区分“局部短时突发”与“持续性异常”, 从而避免把短时 spike 误解释成 level shift 或 seasonal break。

例如:

短时 burst:

10, 10, 10, 80, 85, 80, 10, 10

小波会显示高频能量集中在 80, 85, 80 这一小段, 持续时间短, 前后快速恢复。因此它更支持 spike / burst, 而不是 level shift。

而真正的 level shift 更像:

10, 10, 10, 80, 80, 80, 80, 80

它变化后持续保持新水平, 不能仅凭局部高频能量来解释为 spike。

傅里叶和小波如何共同帮助解决 concept profile 的两个问题?

第一, 针对正常波动导致的错误激活:

- 傅里叶可以判断周期 / 频谱结构是否真的偏离同上下文正常参考;
- 小波可以判断局部高频响应是否只是正常短时噪声或真实突发;
- 这些证据还会在真实 Wcal 或真实正常参考窗口上校准, 避免把目标系统本身的正常波动当成异常 concept。

第二, 针对一个异常触发多个 concept score 的重叠激活:

- 小波先判断是否存在主导 spike / burst;
- 如果 spike / burst 成立, 就对该区域做 masking / imputation;
- 再重新计算 level、seasonal、correlation 等证据;
- 傅里叶进一步验证 seasonal score 是否真的对应周期结构变化。

综上, 让它们各自承担明确功能:

傅里叶: 验证周期 / 频谱结构是否真的变化, 主要服务于 seasonal break。

小波: 定位局部短时高频异常, 主要服务于 spike / burst 识别和去纠缠。

第二步: 用 TimeRCD-style synthetic labels 训练轻量 concept extractor

TimeRCD 合成数据里知道真实注入机制:

TimeRCD-style synthetic data 中的异常注入机制可能是细粒度的, 不一定只对应 ADOrchestra 的五个最终 concept。因此, 这一步不要求 synthetic injection type 和 ADOrchestra concept 一一对应, 而是建立一个 many-to-one 的 label mapping: 把多个细粒度注入机制归并到五个 coarse-grained concept labels 上。

例如:

point spike / upward spike / downward spike / short burst
→ spike label

sudden increase / sudden decrease / persistent level change / spike followed by shift
→ level-shift label, 或 spike + level-shift multi-label

frequency change / amplitude scaling / waveform change / phase shift / add or remove harmonic /
periodic energy change
→ seasonal-break label

conditional value deviation / context-dependent abnormal segment
→ contextual-deviation label

cross-variate propagation / dependency change / correlation-structure change
→ correlation-break label

shake / localized high-frequency vibration
→ spike label 或 spike + seasonal/spectral auxiliary label, 取决于持续时间和频谱证据

对于复合异常, 采用 multi-label, 而不是强行归为单一 concept。例如:

spike followed by level shift
→ spike + level shift

localized burst with persistent frequency change
→ spike + seasonal break

single-variable spike that induces cross-variable propagation
→ spike + correlation break

context-dependent abnormal value with seasonal phase deviation
→ contextual deviation + seasonal break

因此, 对第 j 个 synthetic window, 我们构造一个多标签 concept vector:

$$\mathbf{c}_j^{syn} = [c_{j,spike}^{syn}, c_{j,level}^{syn}, c_{j,season}^{syn}, c_{j,context}^{syn}, c_{j,corr}^{syn}] \in \{0, 1\}^5$$

其中每一维表示该窗口是否包含对应 concept。例如:

$$\mathbf{c}_j^{syn} = [1, 0, 0, 0, 0]$$

表示该窗口只包含 spike;

$$\mathbf{c}_j^{syn} = [1, 1, 0, 0, 0]$$

表示该窗口同时包含 spike 和 level shift;

$$\mathbf{c}_j^{syn} = [1, 0, 1, 0, 0]$$

表示该窗口同时包含 spike 和 seasonal break。

这样做的好处是: 即使 synthetic data 里的注入机制很细、很复杂, 最终也可以统一映射到 ADOrchestra 的五个 concept 上。

然后可以训练一个轻量 concept extractor:

$$\hat{\mathbf{c}}_j = f_\theta(\mathbf{e}_j)$$

把第 j 个窗口的证据特征 $\mathbf{e}_j$ 输入一个小模型 f_θ ，输出这个窗口的 concept profile $\hat{\mathbf{c}}_j$ 。其中：

- $\mathbf{e}_j$: 第 j 个窗口的可解释证据特征，包括原有统计证据、傅里叶证据、小波证据、依赖结构证据和上下文证据（刚才第一步提取的证据特征）；
- f_θ : 轻量 concept extractor，比如MLP / Logistic Regression / 小型 GBDT
- $\hat{\mathbf{c}}_j$: 输出的 concept profile；
- $\mathbf{c}_j^{syn}$: 由 synthetic injection labels 映射得到的 multi-label concept target。监督标签来自 TimeRCD 合成数据中的异常开关。

训练目标：

$$\mathcal{L}_{concept} = \text{BCE}(\hat{\mathbf{c}}_j, \mathbf{c}_j^{syn})$$

$\mathcal{L}_{concept}$ 是让模型预测的 concept profile 接近合成数据真实 concept 标签的训练损失；BCE 是 Binary Cross-Entropy（二元交叉熵），适合这种 multi-label setting。因为一个窗口可能同时包含多个 concept，所以这里不能使用 softmax 单分类，而应该对五个 concept 分别判断是否存在。

展开写就是：

$$\mathcal{L}_{concept} = - \sum_{k=1}^5 \left[c_{j,k}^{syn} \log(\hat{c}_{j,k}) + (1 - c_{j,k}^{syn}) \log(1 - \hat{c}_{j,k}) \right]$$

这一步的作用是：不再完全依赖人工规则直接判断 spike、level shift 或 seasonal break，而是利用 synthetic injection labels 作为 concept-level supervision，让轻量模型学习“可解释证据组合”到五个 coarse concept 的映射关系。由于输入仍然是人工设计的可解释 evidence features，因此它不是黑箱 detector，而是一个 evidence-to-concept mapping module。

需要注意的是，TimeRCD-style synthetic data 在这里只用于 **concept-level supervision / concept extractor pretraining**，不能用于 ADOrchestra 主流程中的 Wopt、Wcal、Wval 或 Wtest 主结果。

第三步：真实数据校准，解决正常波动误激活的问题

合成数据训练出来的 extractor 到真实数据上不能直接用。因为真实系统有正常波动，并且不同真实系统里的“正常波动强度”完全不同。例如系统 A 可能非常平稳，但系统 B 本来就波动大。所以即使在正常数据里，spike score 这个计算出来的分数也不会永远是 0，它会因为正常噪声、正常波动、周期峰值、工况变化而有一个正常范围。所以我们要估计的是：在真实正常状态下，spike score 通常会是多少、level score 通常会是多少、seasonal score 通常会是多少等等。即：每个 concept score 的正常分布，从而计算 spike score 等值相对于该系统自己的正常波动范围高不高。

理论上，应该要在真实 Wcal 或真实正常参考窗口上估计每个 concept 的正常分布。注意：某种 score 在正常数据里可能本来就比另一种 score 高，所有每个 concept 分开校准。

对每个 concept k ，计算真实正常窗口中的中位数和 Median Absolute Deviation (MAD)：

$$m_{k,z}^{real} = \text{median}(\hat{c}_{j,k} : W_j \in \mathcal{N}_{real,z})$$

$$d_{k,z}^{real} = \text{MAD}(\hat{c}_{j,k} : W_j \in \mathcal{N}_{real,z})$$

具体举个例子来说，

假设在上下文 z 下，有 n 个真实正常窗口：

$$\mathcal{N}_{real,z} = \{W_1, W_2, \dots, W_n\}$$

每个窗口都有一个 spike score：

$$\hat{c}_{1,spike}, \hat{c}_{2,spike}, \dots, \hat{c}_{n,spike}$$

那么 spike concept 的正常中位数就是：

$$m_{\text{spike},z}^{\text{real}} = \text{median}(\hat{c}_{1,\text{spike}}, \hat{c}_{2,\text{spike}}, \dots, \hat{c}_{n,\text{spike}})$$

然后每个正常窗口的 spike score 都减去这个中位数，并取绝对值：

$$|\hat{c}_{1,\text{spike}} - m_{\text{spike},z}^{\text{real}}|, |\hat{c}_{2,\text{spike}} - m_{\text{spike},z}^{\text{real}}|, \dots, |\hat{c}_{n,\text{spike}} - m_{\text{spike},z}^{\text{real}}|$$

最后再取这些绝对差值的中位数：

$$d_{\text{spike},z}^{\text{real}} = MAD_{\text{spike},z}^{\text{real}} = \text{median}(|\hat{c}_{1,\text{spike}} - m_{\text{spike},z}^{\text{real}}|, |\hat{c}_{2,\text{spike}} - m_{\text{spike},z}^{\text{real}}|, \dots, |\hat{c}_{n,\text{spike}} - m_{\text{spike},z}^{\text{real}}|)$$

如果不是 spike，而是任意 concept k ，比如 level、season、corr，那么写成：

$$m_{k,z}^{\text{real}} = \text{median}(\hat{c}_{1,k}, \hat{c}_{2,k}, \dots, \hat{c}_{n,k})$$

然后校准当前窗口 W_j 的 concept score：

$$c_{j,k}^{\text{cal}} = \frac{\hat{c}_{j,k} - m_{k,z_j}^{\text{real}}}{d_{k,z_j}^{\text{real}} + \epsilon}$$

为了和 原文件 `Label Generation (Explanation).pdf` 里已经出现过的鲁棒 z-score 对齐，写为：

$$s_{k,z}^{\text{real}} = 1.4826 \cdot d_{k,z}^{\text{real}} + \epsilon$$

$$c_{j,k}^{\text{cal}} = \frac{\hat{c}_{j,k} - m_{k,z_j}^{\text{real}}}{s_{k,z_j}^{\text{real}}}$$

意思是：当前 concept score 相对于真实目标域同上下文正常波动是否异常，而不是看绝对值。例如早高峰流量升高，如果历史早高峰本来就这样，那么校准后不会被误认为 spike 或 level shift。这一步拟解决正常波动导致 false concept activation 的问题。

注意，真实数据校准不仅作用于 spike、level、season 等最终 concept score，也可以作用于傅里叶和小波 evidence。例如，正常早高峰可能本来就具有较高频谱能量变化，正常机械振动也可能本来就有一定高频小波能量。因此，傅里叶特征和小波特征也应在真实正常参考窗口上估计其正常范围，再作为可靠 evidence 输入后续判断。这样可以减少正常周期变化或正常高频振动造成的 false concept activation。

第四步：Concept 去纠缠，解决一个异常触发多个 concept

经过前面步骤后，每个窗口 W_j 会得到一组 raw concept scores：

$$\mathbf{c}_j^{\text{raw}} = [c_j^{\text{spike,raw}}, c_j^{\text{level,raw}}, c_j^{\text{season,raw}}, c_j^{\text{context,raw}}, c_j^{\text{corr,raw}}]$$

但这些 raw scores 不能直接解释为“同时发生了多种异常机制”。因为一个主导异常可能会带动其他 concept score 升高。

例如：

局部 spike / burst 可能带动 level、seasonal、correlation score 升高；
 level shift 可能带动 contextual deviation 和 seasonal residual 升高；
 seasonal break 可能带动 contextual deviation 升高；
 单变量 outlier 可能扰乱 correlation score；
 correlation break 可能让多个变量的 contextual residual 同时升高。

所以第四步的目标是：判断每个高分 concept 是真实独立机制，还是其他主导 concept 造成的伴随响应。

下面给出一种可操作的去纠缠流程（just my draft）：

4.1 先生成候选主导 concept

先根据校准后的 concept score 和 concept-specific validation evidence，为每个 concept 计算一个候选主导分数：

$$D_j^c, \quad c \in \{spike, level, season, context, corr\}$$

其中 $D_j^c \in [0, 1]$ 表示 concept c 作为窗口 W_j 主导异常机制的可能性。这里的 D_j^c 不是直接等于 raw concept score，而是由两部分组成：

$$D_j^c = \text{Normalize} \left(c_j^{c, cal}, \mathbf{v}_j^c \right)$$

其中：

- $c_j^{c, cal}$ ：经过真实数据校准后的 concept score；
- $\mathbf{v}_j^c$ ：concept c 对应的验证证据；
- $\text{Normalize}(\cdot)$ ：可以是一个简单加权函数、logistic scoring function，或者由验证集学习得到的轻量 scoring head，用于把候选主导分数归一化到 $[0, 1]$ 。

也就是说，这里的 D_j^c 是一个 **candidate dominance score**，用于排序和筛选候选主导 concept，而不是最终严格证明某个 concept 一定为真。

4.1.1 Spike / burst 的候选主导证据

Spike / burst 的候选主导分数由以下证据共同支持：

calibrated spike score 高；
Hampel 幅值异常证据高；
一阶差分 / 导数异常证据高；
峰值突出度证据高；
小波局部性高；
突发持续时间短；
短时冲击强度高；
异常后恢复快。

因此可以写成：

$$D_j^{spike} = \text{Normalize} \left(c_j^{spike, cal}, e_j^{hampel}, e_j^{diff}, e_j^{prom}, Locality_j, ShortDuration_j, ShockStrength_j, Recovery_j \right)$$

含义是：spike / burst 不仅要 spike score 高，还应该表现为局部、短时、高幅值、高导数变化，并且前后能够较快恢复。

4.1.2 Level shift 的候选主导证据

Level shift 的候选主导分数由以下证据共同支持：

calibrated level score 高；
左右窗口稳健中位数差异明显；
CUSUM 变化统计量高；
变化持续存在；
变化后形成新的稳定水平；
小波局部性不应过高。

因此可以写成：

$$D_j^{level} = \text{Normalize} \left(c_j^{level, cal}, e_j^{median-shift}, e_j^{CUSUM}, Persistence_j, LongDuration_j, StabilityAfterShift_j, 1 - Locality_j \right)$$

含义是：level shift 不仅要 level score 高，还要体现“持续水平切换”。如果小波局部性很高、持续时间很短，那么更像 spike / burst，而不是 level shift。

4.1.3 Seasonal break 的候选主导证据

Seasonal break 的候选主导分数由以下证据共同支持：

calibrated seasonal score 高；
同周期相位偏离明显；
periodogram energy 变化明显；
频谱距离高；
主频偏移高；
周期能量损失明显；
频谱熵升高。

因此可以写成：

$$D_j^{season} = \text{Normalize} \left(c_j^{season,cal}, e_j^{phase}, e_j^{periodogram}, s_j^{spec}, s_j^{peakshift}, s_j^{periodloss}, s_j^{entropy} \right)$$

含义是：seasonal break 不仅要 seasonal score 高，还需要傅里叶 / 频谱证据支持周期结构确实发生变化。若只是某个点偏离历史同周期相位，但频谱结构没有明显变化，则更可能是 contextual deviation 或 spike / burst 的副作用，而不是 seasonal break。

4.1.4 Contextual deviation 的候选主导证据

Contextual deviation 的候选主导分数由以下证据共同支持：

calibrated context score 高；
条件范围偏离明显；
中位数基线预测误差高；
预测误差鲁棒 z-score 高；
同工况正常参考残差高；
但没有强证据表明它完全由 spike、level shift 或 seasonal break 解释。

因此可以写成：

$$D_j^{context} = \text{Normalize} \left(c_j^{context,cal}, e_j^{cond-range}, e_j^{median-error}, e_j^{error-z}, e_j^{same-regime}, \eta_j^{not-explained} \right)$$

其中 $\eta_j^{not-explained}$ 表示该 contextual deviation 不能被其他更具体的主导 concept 充分解释的程度。它可以在去纠缠阶段通过 removal / adjustment 判断，而不需要在这里写成固定公式。

含义是：contextual deviation 关注的是“当前值在当前上下文下不合理”。但如果这个不合理完全是由明显 spike、level shift 或 seasonal break 导致的，那么它更适合作为 secondary response，而不是 primary concept。

4.1.5 Correlation break 的候选主导证据

Correlation break 的候选主导分数由以下证据共同支持：

calibrated correlation score 高；
当前相关矩阵与正常参考相关矩阵距离大；
节点级相关偏移明显；
多个变量对关系发生变化；
不是由单个变量 outlier 造成的相关矩阵扰动。

因此可以写成：

$$D_j^{corr} = \text{Normalize} \left(c_j^{corr,cal}, s_j^{corr,raw}, e_j^{node-corr}, e_j^{pair-corr}, \eta_j^{multi-var}, \eta_j^{outlier-controlled} \right)$$

其中：

- $\eta_j^{multi-var}$ ：表示相关结构变化是否涉及多个变量或多个变量对，而不是单个变量异常；
- $\eta_j^{outlier-controlled}$ ：表示控制单变量 outlier 后，相关结构变化是否仍然存在。

含义是：correlation break 需要说明变量之间的关系真的发生变化。如果只是某个变量出现极端 outlier，导致相关矩阵被扰乱，则不应直接作为主导 correlation break。

4.2 根据候选主导 concept 做 intervention / residualization 验证

对于每个候选主导 concept q ，不能简单假设都可以构造：

$$W_j^{(-q)} = \text{Remove}_q(W_j)$$

因为不同 concept 的“去除方式”并不一样。

例如，spike / burst 可以通过 masking 或 imputation 去除局部异常点；但 level shift、seasonal break、correlation break 和 contextual deviation 并不一定能被直接“删掉”。因此，这里更准确的做法是：根据候选主导 concept 的类型，构造对应的 **intervened window / adjusted representation**，再重新计算其他 concept 的分数。

可以统一写成：

$$\widetilde{W}_j^{(q)} = \mathcal{I}_q(W_j)$$

其中 $\mathcal{I}_q(\cdot)$ 表示针对候选主导 concept q 的 intervention / adjustment 操作，而不是简单 remove。

不同 concept 对应的操作可以是：

```

spike / burst:
  RemoveSpike(w_j)
  即对局部 spike / burst 区域进行 masking、imputation 或 winsorization。

single-variable outlier:
  ControlOutlier(w_j)
  即对单变量极端值进行 winsorization、masking 或 imputation，再重新计算相关结构。

level shift:
  AdjustLevel(w_j)
  即以变化后的新水平作为局部基线，或去除水平偏移后重新计算其他 concept。

seasonal break:
  AdjustSeason(w_j)
  即用新的周期结构、去季节化残差或频谱调整后的表示重新计算其他 concept。

correlation break:
  AdjustCorrelation(w_j)
  即在控制单变量 outlier 后，重新估计变量相关结构，并判断其他 concept 是否仍然存在。

```

然后重新计算其他 concept r 的分数：

$$c_j^{r|q\text{-adjusted}} = \text{Score}_r(\widetilde{W}_j^{(q)})$$

其中：

- q ：候选主导 concept；
- r ：其他可能被污染的 concept；

- $\mathcal{I}_q(\cdot)$: 针对 concept q 的 intervention / adjustment 操作;
- $Score_r(\cdot)$: 重新计算 concept r 的证据或分数。

然后定义 concept r 被 concept q 影响的程度:

$$\Delta_j^{r \leftarrow q} = c_j^{r, raw} - c_j^{r|q\text{-adjusted}}$$

如果:

$$\Delta_j^{r \leftarrow q}$$

很大, 说明 concept r 的原始升高很可能是 concept q 造成的副作用, 而不是真实独立机制。

如果调整后:

$$c_j^{r|q\text{-adjusted}}$$

仍然较高, 则说明 concept r 可能不是副作用, 而是一个真实共存的 concept。

4.3 常见去纠缠关系

A. Spike / burst 污染 level shift

如果 spike / burst 是候选主导 concept, 则先去除 spike / burst 区域:

$$W_j^{(-spike)} = RemoveSpike(W_j)$$

再重新计算 level score:

$$c_j^{level|spike\text{-removed}} = LevelScore(W_j^{(-spike)})$$

污染量:

$$\Delta_j^{level \leftarrow spike} = c_j^{level, raw} - c_j^{level|spike\text{-removed}}$$

如果该值很大, 说明 level score 是 spike / burst 的副作用。

B. Spike / burst 污染 seasonal break

$$c_j^{season|spike\text{-removed}} = SeasonScore(W_j^{(-spike)})$$

同时结合傅里叶验证:

$$c_j^{season, valid} = c_j^{season|spike\text{-removed}} \cdot g(s_j^{spec}, s_j^{peakshift}, s_j^{periodloss})$$

如果去 spike 后 seasonal score 下降, 且傅里叶证据低, 则 seasonal break 被抑制。

C. Spike / burst 或单变量 outlier 污染 correlation break

如果某个变量发生强 outlier, 则先对该变量进行 masking / imputation / winsorization:

$$W_j^{(-outlier)} = RemoveOutlier(W_j)$$

重新计算相关矩阵:

$$\tilde{R}_j = corr(W_j^{(-outlier)})$$

原始相关结构偏移:

$$s_j^{corr, raw} = \|R_j - R_{z_j}^{normal}\|_F$$

控制 outlier 后的相关结构偏移：

$$s_j^{corr|outlier-removed} = \|\tilde{R}_j - R_{z_j}^{normal}\|_F$$

污染量：

$$\Delta_j^{corr \leftarrow outlier} = s_j^{corr,raw} - s_j^{corr|outlier-removed}$$

如果该值很大，说明 correlation break 很可能只是单变量 outlier 扰乱相关矩阵造成的。

D. Level shift 造成 contextual deviation

真正的 level shift 会让当前窗口在原上下文参考下显得异常，因此 contextual deviation 也可能升高。

这时要判断 contextual deviation 是否只是 level shift 的伴随响应。

可以定义：

$$c_j^{context|level-adjusted} = ContextScore(AdjustLevel(W_j))$$

其中 $AdjustLevel(W_j)$ 表示把 level shift 的新水平作为局部基线进行调整后，再计算 contextual deviation。

污染量：

$$\Delta_j^{context \leftarrow level} = c_j^{context,raw} - c_j^{context|level-adjusted}$$

如果该值很大，说明 contextual deviation 主要是 level shift 造成的伴随响应。

E. Seasonal break 造成 contextual deviation

seasonal break 也会让当前值偏离历史同相位正常范围，从而提高 contextual deviation。

可以定义：

$$c_j^{context|season-adjusted} = ContextScore(AdjustSeason(W_j))$$

其中 $AdjustSeason(W_j)$ 表示用新的周期结构或去季节化后的残差重新计算 context score。

污染量：

$$\Delta_j^{context \leftarrow season} = c_j^{context,raw} - c_j^{context|season-adjusted}$$

如果该值很大，说明 contextual deviation 主要是 seasonal break 的伴随响应。

F. Correlation break 造成多个变量的 contextual deviation

如果变量之间的关系失效，多个变量可能同时出现上下文残差升高。

这时要判断 contextual deviation 是否由结构关系变化引起。

可以定义：

$$c_j^{context|corr-adjusted} = ContextScore(AdjustCorrelation(W_j))$$

或更简单地，在实践中判断：

correlation break score 高；
多个变量的 context score 同时升高；
控制单变量 outlier 后 correlation break 仍然存在。

则可以认为：

primary concept = correlation break
secondary response = contextual deviation

4.4 去纠缠后的 concept 分数更新

对每个 concept r ，可以根据污染量对原始分数进行修正：

$$c_j^{r,dis} = c_j^{r,raw} \cdot (1 - \rho_j^r) + c_j^{r|q^*-removed} \cdot \rho_j^r$$

其中：

- q^* ：最可能的主导 concept；
- ρ_j^r ：concept r 被主导 concept 污染的置信度；
- $c_j^{r,dis}$ ：去纠缠后的 concept 分数。

如果不想写得这么复杂，也可以只做规则判断：

如果去除主导 concept 后，某个 concept 分数显著下降，则把它标记为 suppressed concept；如果仍然较高，则保留为 secondary or co-existing concept。

4.5 最终判断

最终不只看 raw concept score，而是综合：

raw concept score
candidate dominance score
removal 后的 concept score
污染量 Δ
傅里叶验证证据
小波定位证据
persistence / stability 证据
correlation outlier-control 证据

输出：

primary concept
secondary response
co-existing concept
suppressed concept

其中：

- **primary concept**：最可能的主导异常机制；
- **secondary response**：由主导 concept 引起的伴随响应；
- **co-existing concept**：去除主导 concept 后仍然存在的独立 concept；
- **suppressed concept**：原始分数升高，但去纠缠后不再认为是真实独立机制的 concept。

例如，如果：

D_{spike} 高；
去 spike 后 level score 明显下降；
去 spike 后 seasonal score 明显下降；
傅里叶频谱证据低；
控制单变量 outlier 后 correlation score 下降；

则输出：

```
primary concept = spike / burst
secondary response = contextual deviation
suppressed concepts = level shift, seasonal break, correlation break
```

如果：

D_{spike} 高；

去 spike 后 seasonal score 仍然高；

傅里叶频谱证据也高；

则输出：

```
primary concept = spike / burst
co-existing concept = seasonal break
```

也就是说，这一步不是强行只保留一个 concept，而是区分：

```
主导机制
伴随响应
真实共存机制
被抑制的误激活
```

小结：如果某个变量自己出现了一个极端 spike，它可能会把相关矩阵扰乱。我们不能马上说变量关系真的断裂了，而应该先控制或去除这个单变量异常，再重新计算相关结构。如果去除后 correlation break 消失，那它只是单变量 outlier 的副作用；如果仍然存在，才更像真实相关结构变化。

第五步：最终输出不要只是分数，而是主次关系

最终 concept profile 输出可以包括：

```
calibrated concept profile
primary concept
secondary responses
suppressed concepts
evidence
```

例如：

```
{
  "concept_profile": {
    "spike": 0.91,
    "level_shift": 0.18,
    "seasonal_break": 0.16,
    "contextual_deviation": 0.22,
    "correlation_break": 0.08
  },
  "primary_concept": "spike",
  "secondary_responses": ["contextual_deviation"],
  "co_existing_concepts": [],
  "suppressed_concepts": ["level_shift", "seasonal_break"],
  "evidence": {
```

```
"spike": "high wavelet-localized energy, short duration, and rapid recovery",
"level_shift": "level evidence decreases after masking the spike region",
"seasonal_break": "Fourier spectral deviation remains low after spike removal",
"contextual_deviation": "the spike also causes a local context-conditioned residual increase",
"correlation_break": "inter-variable correlation remains close to the normal reference"
}
}
```

注意: **secondary_responses** 和 **co_existing_concepts** 的区别在于:

secondary_responses 是“伴随响应”，不是独立异常机制；

co_existing_concepts 是“真实共存的异常概念”，是独立机制（去纠缠后仍然存在的独立 concept）。如果没有 co-existing concept, 可以为空数组。

这样就不会把一个 spike 解释成:

spike + contextual + level shift + seasonal break 同时发生

而是解释成:

主导异常是 spike; 这个 spike 也让当前窗口相对于上下文参考显得不合理, 但它不是另一个独立机制。level / seasonal 分数升高只是 spike 的副作用。

其中, **suppressed_concepts** 可以理解成: 原始分数可能升高, 但经过校准、傅里叶/小波验证、去 spike 重估后, 判定它不是独立异常机制, 所以被抑制掉的 concept。